

FractureFinder: Automated Classification of Bone Breaks in X-rays

PROYECTO IA I


Juan Felipe Serrano Contreras - 2230088

Felipe Vargas García - 2230090

Javier Gomez Villaruel - 223095



ITINERARIO





Introducción al Dataset

El dataset seleccionado es "Bone Break Classification Image Dataset". Este está enfocado en la detección, clasificación y localización de fracturas óseas. Este dataset esta compuesto por imagenes de rayos X.



Composicion del Dataset

- Total Imagenes X-ray: 1129
 - Imagenes de entrenamiento: 989 en formato ".jpg"
 - Imagenes de prueba:140 en formato ".jpg"
- Partes del cuerpo que estan en el dataset: Codo, dedo, antebrazo, húmero, hombro, fémur, tibia, rodilla, cadera, muñeca, médula espinal y otras muestras de huesos sano.
- Tipos de fracturas:fracturas por avulsión,conminutas, fracturas-luxaciones, fracturas en tallo verde, hairline, impactadas, longitudinales, oblicuas, patológicas y espirales.


Visualizacion de una muestra de imagenes estandarizadas



Histogramas de Media y Varianza



Distribucion de las clases



Entrenamiento

Particionado 80/20

- Se hace un reorganizado del dataset ya que el mismo venia particionado dentro de categorías de manera que era más difícil de acceder para el modelo, por lo que se implementó una función para reorganizar el dataset a una estructura Tipo_Fractura/Train y Tipo_Fractura/Test.
- Las imágenes fueron cargadas, redimensionadas a 256x256 píxeles y convertidas a escala de grises. Luego las imágenes fueron aplanadas para que sean compatibles con los modelos de scikit-learn y las etiquetas de las fracturas se codificaron numéricamente.


Shape of X_train: (903, 65536)

Shape of X_test: (226, 65536)

Shape of y_train: (903,)

Shape of y_test: (226,)

Number of classes: 10




Modelos Evaluados

Se entrenaron y evaluaron varios modelos de clasificación sobre el dataset completo:


1. **Árbol de Decisión (Decision Tree):** Se obtuvo una precisión de aproximadamente 20.80%.
2. **Bosque Aleatorio (Random Forest):** Mejoró la precisión a cerca del 34.96%.
3. **Máquina de Vectores de Soporte (SVM):** Presentó una precisión de aproximadamente 30.53%.
4. **Perceptrón Multicapa (MLP) con TensorFlow:** Este modelo mostró un rendimiento similar, con una precisión final de alrededor del 23.45%.



Rendimiento del MLP



Visualización del comportamiento de los modelos




Particionado 80/20 clases seleccionadas

Debido al bajo desempeño del modelo (basandonos en la metrica del accuracy) decidimos enfocarnos en dos categorias

- Hairline fracture
- Fracture Dislocation
- Impacted fracture
- Oblique fracture
- Pathological fracture
- Spiral Fracture
- Longitudinal fracture
- Avulsion fracture

Nueva distribución y balance de las clases seleccionadas



Nuevos resultados de los modelos

Utilizando los mismos modelos reevaluamos el dataset con solo 2 clases:

1. **Árbol de Decisión (Decision Tree)**: Se obtuvo Aumento de 199.52% respecto a su rendimiento inicial, con un accuracy de aproximadamente 62.63%
2. **Bosque Aleatorio (Random Forest)**: Se consagra como el mejor modelo en ambos escenarios, obteniendo al rededor de 80.33%.
3. **Máquina de Vectores de Soporte (SVM)**: Su precisión con dos clases es de aproximadamente 68.85%.
4. **Perceptrón Multicapa (MLP) con TensorFlow**: Como era de esperar su rendimiento también aumento con un puntaje cerca del 67.21%.

1

Accuracy: 0.6230
Error: 0.3770

2


Accuracy: 0.8033
Error: 0.1967



3

Accuracy: 0.6885
Error: 0.3115


4

Accuracy: 0.6721
Test loss: 0.7172






Nuevas matrices de confusión



K-means


En esta sección, ejecutamos K-Means con el número exacto de clases seleccionadas y visualizamos la diferencia entre los clusters encontrados por el algoritmo y la clasificación médica real. Llegando a 3 conclusiones



- División Geométrica vs. Médica: K-Means intenta agrupar los puntos basándose en la cercanía física en el espacio de características. Sin embargo, en el gráfico de la derecha (Ground Truth), vemos que las clases de fracturas están completamente traslapadas.
 - Traslape de Características: Esto indica que la intensidad de los píxeles y las formas básicas capturadas por PCA no son suficientes para diferenciar una fractura de otra de forma no supervisada.
 - Limitación del Algoritmo: K-Means asume que los clusters son esféricos y bien separados, lo cual no ocurre en este dataset médico donde la variabilidad intra-clase es alta y la inter-clase es baja.
- La segmentación que hace K-Means es puramente matemática y carece de significado clínico en este espacio de baja dimensionalidad.

DBScan

Vamos a aplicar DBSCAN buscando una configuración que logre separar al menos algunos puntos, comparándolo con la distribución real de las fracturas.



Los resultados de DBSCAN confirman nuestra sospecha: el algoritmo no logró encontrar ningún cluster (identificó los 243 puntos como ruido). Esto sucede porque DBSCAN requiere que existan zonas donde los puntos estén muy 'apretados' (densos) separadas por espacios vacíos. En este, las imágenes son tan similares entre sí que, al proyectarlas en 2D con PCA, forman una nube uniforme sin separaciones clara


Conclusión del análisis de Clustering:

K-Means (k=2): Logra dividir los datos artificialmente, pero sus grupos no coinciden con las categorías médicas, lo que indica que la geometría de los píxeles no refleja directamente el tipo de fractura. DBSCAN: Falla al no encontrar variaciones de densidad significativas, tratando todo el conjunto como una sola masa de datos


Visualizaciones adicionales

Este gráfico muestra cómo se distribuyen las clases reales de fracturas en un espacio bidimensional reducido mediante PCA. Cada punto representa una imagen, y el color indica su tipo de fractura. Esto nos permite observar visualmente cuán distintas o superpuestas son las categorías en términos de las características extraídas por PCA.

Distribución de Clases Reales de Fracturas en el Espacio PCA (Entrenamiento)



Distribución de Todas las Clases Reales de Fracturas en el Espacio PCA (Entrenamiento)



Conclusiones



- Límites de la IA Tradicional en Medicina: La alta similitud visual entre múltiples tipos de fracturas genera un solapamiento crítico de datos. Los modelos analizados carecen de la capacidad de interpretar el contexto clínico, limitando su confiabilidad en diagnósticos multiclase complejos.

Validación por Clustering: El fracaso de K-Means y DBSCAN para identificar grupos médicos reales demuestra matemáticamente que la distribución física de los píxeles no refleja la naturaleza de la lesión,

Robustez del Aprendizaje en Conjunto: Random Forest se consolidó como la herramienta clásica más viable debido a su capacidad para mitigar el ruido visual y el sobreajuste mediante la combinación de múltiples árboles de decisión.

Rediseño del Alcance: La reducción a dos clases evidencia que simplificar las fronteras de decisión transforma un problema intratable para la IA clásica en un escenario con métricas operables y de alta precisión.